第九届传智杯 AI WEB 开发挑战赛 · 参赛作品

智析 ChatBI

AI 对话式企业数据分析与可视化平台

技术文档

项目	内容
作品名称	智析 ChatBI——AI 对话式企业数据分析与可视化平台
参赛赛项	第九届传智杯 AI WEB 开发挑战赛 · AI 数据分析与可视化
团队名称	Team YK
团队成员	叶锦豪、洪富凯
指导教师	黄淳笙
所属院校	广东东软学院
文档版本	V1.0.1
编制日期	2026-10-31

本文件为第九届传智杯 AI WEB 开发挑战赛提交材料。文档中的演示数据为合成数据，不代表真实企业经营事实；所有密钥均通过环境变量注入，不写入文档与仓库。

目 录

01 项目概述

02 需求分析

03 系统架构设计

04 AI 技术方案

05 核心功能实现

06 测试与部署

07 创新点

08 总结与展望

阅读提示：第 1–2 章为项目与需求；第 3 章为架构；第 4 章为重点 AI 技术方案；第 5 章为核心功能实现；第 6 章为测试与部署；第 7 章明确列出创新点；第 8 章为总结与展望。

1 项目概述

1.1 作品名称与定位

智析 ChatBI——AI 对话式企业数据分析与可视化平台。

它不是“聊天窗 + 图表”，而是一套把自然语言、受控执行、证据链和可视化组织在一起的分析工作台：用户用中文提出经营问题，系统在受控边界内完成查询、计算、成图和解释，并把每个结论回指到 SQL 审计、查询结果、Artifact 或语义图谱。

本项目在开源项目 DataPilot 的受控数据分析工作台基础上二次开发，**已获得原作者许可**；基线的版权与署名按原作者约定保留。本作品的重点增量是中文企业场景产品化、经营驾驶舱、DeepSeek 流式问数、演示数据、证据呈现、评测体系与交付工程。

1.2 背景与问题

企业并不缺数据，缺的是“把数据变成洞察”的通路。传统 BI 的分析链路是“业务提需求 → 分析师排期 → 写 SQL → 配图表 → 解释口径”，存在四个结构性问题：

问题	具体表现	后果
门槛高	需要理解表结构、字段、SQL、图表配置	非技术岗位依赖分析师排期
链路长	取数、做图、解释由不同角色接力	响应以天或周计
结论不可信	聊天工具给出的数字没有来源	无法回答“这个数从哪来”
接入不安全	让模型自由生成 SQL 并连库	写库、越权、泄露、成本失控

智析 ChatBI 的解法是：**对话式交互 + 受控执行 + 证据链 + 可复现演示。**模型负责理解与表达，运行时决定能用什么工具、读什么数据、给出什么证据。

1.3 目标用户与价值

角色	目标	平台提供的能力
业务 / 运营 / 销售	不写 SQL 也能查数	中文提问、推荐问题、图表与结论
管理者	快速看清经营状况	驾驶舱、趋势、区域、渠道、预警
数据分析师	核对口径与证据	Schema、遮蔽、Run、SQL 审计、DataLink
模型管理员	安全接入模型	配置、能力探测、测试、激活
评审人员	无 Key 验证作品	演示模式、906 条订单、完整操作手册

价值可以概括为四点：

- **用户价值**：降低分析门槛，让业务人员“像聊天一样问数据”。
- **企业价值**：盘活数据资产，缩短“提问—取数—成图—决策”的链路。
- **技术价值**：探索 AI + BI 的轻量化落地形态，形成可审计的对话式分析闭环。
- **社会价值**：推动数据分析普惠，让非专业用户也具备基本的数据洞察能力。

1.4 核心能力

模块	能力
经营驾驶舱	订单金额、活跃客户、客单价、毛利率；月度营收/毛利趋势、收入来源、区域 TOP5、经营预警
智能问数	中文提问、推荐问题、DeepSeek 流式回答、失败降级、来源与截至日期标识
受控分析工作台	Session / Run、阶段事件、Trace DAG、工具调用、SQL 审计、Artifact、证据引用、历史回放
DataLink 语义图谱	Schema 建图、业务实体/属性/关系、字段映射、Join 线索、版本与修订、MCP 语义检索
数据资产	CSV / SQLite 上传、MySQL 连接、Schema 检查、字段遮蔽确认、DataLink 构建
模型设置	OpenAI-compatible 配置、能力探测、测试、激活；密钥只存服务端
洞察报告	结论、口径、证据状态、限制说明、Markdown 导出
项目台账 / 收支管理	项目阶段与进度、收入/成本/回款明细（演示记录，不写外部系统）

1.5 双模式运行

模式	触发条件	分析路径	数据来源	页面标识
演示模式	无数据源 / 无激活模型 / API 不可用	本地确定性回答，或 DeepSeek 聚合上下文 SSE	chatbi_sales_summary.json	“演示 · 906 条订单”
真实模式	数据源 ready + 遮蔽确认 + 模型激活	受控 Agent Run	数据源只读查询 + Artifact	数据源名称 + Run 状态

演示模式不是“假数据兜底”，而是可独立验收的产品路径：评审不需要 Key、不需要企业数据，也能完成驾驶舱浏览、自然语言提问、报告导出与证据查看。

1.6 项目规模

维度	规模
前端	Vue 3 + TS + Vite，4 个路由、20+ 核心组件、40 个测试文件
后端	FastAPI 单 worker，17 张表、31 个 Alembic 迁移、46 个测试文件
AI 运行时	LangGraph 状态机、4 个白名单工具、25 类 Run 事件
测试	后端 Pytest 772 项、前端 Vitest 282 项
评测	20 题中文电商基准、178 条协议路由用例
文档	18 份开发文档（Markdown + Word）

2 需求分析

2.1 核心用户旅程

步骤	用户动作	系统行为	用户看到
1	打开 /workspace	加载汇总数据、健康状态与导航	指标卡、趋势、渠道、区域、预警、问数框
2	输入“截至 10 月 29 日，各区域营收占比和回款情况如何？”	校验问题，进入 analyzing	发送禁用、脉冲状态、来源标签
3	系统分析	演示走 DeepSeek SSE；真实模式创建 Run 并订阅事件	流式文本 / 阶段事件
4	查看结论	组织结论、口径、来源、限制与证据入口	答案卡、证据按钮、图表联动
5	追问或导出	保留会话上下文；报告导出 Markdown	新回答、报告文件、历史 Run

2.2 功能需求

编号	需求	优先级	验收摘要
FR-01	工作空间与导航	P0	四个路由可访问，切换不整页刷新
FR-02	演示数据与统一汇总	P0	906 条订单，页面指标与 summary 一致
FR-03	数据源接入与 Schema	P0	CSV / SQLite / MySQL 可接入并显示状态
FR-04	字段遮蔽与只读边界	P0	未确认遮蔽不能建 Run；写 SQL 被拒绝并审计
FR-05	自然语言问数	P0	中文提问、推荐问题、追问、输入校验
FR-06	DeepSeek 流式分析	P0	SSE 返回 status / delta / error / done
FR-07	受控 Run 与证据链	P0	Run 可创建、订阅、取消、回放，证据可定位
FR-08	可视化驾驶舱	P0	指标、趋势、渠道、区域、预警完整
FR-09	洞察报告	P1	结论、来源、证据、限制可导出 Markdown
FR-10	项目流程台账	P1	负责人、阶段、进度、交付可见
FR-11	收支管理	P1	收入、成本、回款、明细口径可复算
FR-12	模型配置安全	P0	Key 仅服务端持有，测试通过后才能激活
FR-13	演示降级	P0	API / Key 不可用时主流程仍可演示

2.3 非功能需求

编号	类别	要求	验证
NFR-01	性能	本地演示首屏 1 秒内出现骨架与指标	浏览器 Performance
NFR-02	流式	上游片段到达即转发，不整段缓冲	SSE 冒烟

编号	类别	要求	验证
NFR-03	可用性	异常给出原因与下一步，不暴露堆栈	异常用例
NFR-04	安全	Key 不进入 bundle、Storage、日志、报告、截图	构建产物搜索
NFR-05	数据	SQL 只读、结果限流、审计完整	网关单测
NFR-06	兼容	Windows、Python 3.12、Node 22.12+、Edge/Chrome	构建与手工验收
NFR-07	响应式	1280 / 768 / 390 可操作，无页面级横向溢出	浏览器测量
NFR-08	可维护	前后端分层、接口有契约、命名一致	代码审查
NFR-09	可追溯	P0/P1 有用例与结果	追溯矩阵
NFR-10	一致性	页面指标来自汇总或真实产物	数据对账
NFR-11	恢复	重启恢复中断检查、构建与 Run 终态	重启测试
NFR-12	可观测	request_id、run_id、事件序号、日志脱敏	日志审查

2.4 关键业务规则

编号	规则
BR-01	页面数字必须来自 CSV 生成的 summary JSON 或真实 Run 产物
BR-02	同期比较必须使用相同截止日：10 月 1–29 日对比 9 月 1–29 日
BR-03	缺少漏斗字段时不计算转化率；缺少成本字段时不计算毛利率
BR-04	待回款只统计 payment_status=待回款
BR-05	Key 缺失时显示演示模式，不显示密钥内容
BR-06	真实 Run 失败不得覆盖历史成功结果
BR-07	报告必须标注演示或真实来源
BR-08	未确认遮蔽、Schema 未就绪或模型未激活时不得创建真实 Run
BR-09	模型不得把上下文外数字当作查询事实；无证据的数字不进入结论

2.5 范围边界

- 不写入企业业务库，不修改源数据，不提供 DDL / DML。
- 不替用户做财务、投资、人事等高风险决策。
- 不提供企业级多租户、单点登录、行级权限（V1.0 为单工作空间）。
- 不承诺对任意数据源自动建图；DataLink 建图需要模型配置。
- 演示数据为合成数据，项目台账与收支为演示记录。

2.6 验收基线

所有 P0 通过；P1 可演示；CSV 与 summary 一致；构建、类型检查、前后端测试、DeepSeek 冒烟、健康检查通过；18 份文档同步；构建产物与仓库中搜索不到真实 Key；`.env`、`storage`、`.venv`、`.tmp` 未提交。

3 系统架构设计

3.1 架构原则

原则	落地方式
受控优先	模型不直接接触数据库；所有访问经白名单工具、只读网关、沙箱或 DataLink
证据优先	事实来自查询；答案与 SQL 审计、Artifact、引用材料绑定
双模式运行	无 Key / 无数据源时演示；配置齐全后切换真实 Run
边界清晰	浏览器不持有密钥、不直连模型、不直连 DataLink
单进程一致性	Run、SSE、取消状态在单 worker 内协作
可替换模型	OpenAI-compatible + ModelProfile 抽象供应商
可观测	request_id、run_id、事件序号、Trace DAG、可选 LangSmith

3.2 总体架构



智析 ChatBI 总体架构

架构分为六层：

层	主要组件	职责	明确不做
展示层	4 个视图、20+ 组件	页面、输入、图表、状态	不保存 Key、不连库、不直连模型

层	主要组件	职责	明确不做
API 层	FastAPI routes、middleware	校验、事务、SSE、错误信封	不返回上游原始错误体
应用层	RunExecution、DataSource、ModelProfiles	用例编排、服务装配	不直接拼 SQL
运行时	RunExecutor、Agent Runtime、EventPipeline	状态机、工具、预算、校验	不越过工具白名单
数据访问	SQL Gateway、Sandbox、DataLink Client	只读查询、隔离计算、语义检索	不写源库、不联网、不越权读文件
持久化	Metadata SQLite、storage	Run/Event/Audit/Artifact/Secret	不存明文密钥、不记录完整敏感结果

3.3 三条核心链路

3.3.1 演示问数链路

```
Browser ──POST /ai/deepseek/analyze──▶ FastAPI
                                       ├─ 读取 DEEPSEEK_API_KEY（服务端）
                                       ├─ 构造受限聚合上下文
                                       ├─ AsyncOpenAI Responses API (stream=true)
                                       └─ delta / completed / error → SSE
Browser ◀──status / delta / error / done── FastAPI
```

401/402 不重试；timeout/connection/429/5xx 仅在未输出文本时退避；已输出文本后不重放。Key 缺失或服务不可用时，前端降级为本地确定性回答。

3.3.2 真实 Run 链路

1. 前端在 `/analysis` 选择 Session 与已 ready 的数据源。
2. `POST /sessions/{id}/runs` 携带问题与幂等键。
3. RunExecution 校验会话、幂等键、活跃 Run；解析并冻结数据源、Schema、模型、DataLink 版本、预算与超时。
4. 写入 `runs`、`messages`，追加 `run.queued` 事件，调度后台执行，返回 202。
5. RunExecutor 执行 Agent Graph；工具调用写入审计与事件；最终答案保存证据快照。
6. 前端通过 SSE 增量投影；历史 Run 只读回放，不重复调用模型。

3.3.3 DataLink 语义链路

```
Schema ──▶ DataLink (8281)
           ├─ 建图：表→实体，字段→属性，外键/采样→关系与 Join
           ├─ 修订：草稿 → 校验 → 发布版本
           ├─ 检索：MCP 按业务词召回实体、属性、关系、字段映射
           └─ 消费：记录 Run 使用的版本与命中项
```

DataLink 解决“业务词不是物理字段名”的问题：用户说“回款”，图谱把它映射到 `payment_status`；用户说“客户”，图谱给出实体与主键；用户说“订单明细”，图谱给出 Join 路径。

3.4 组件与代码边界

组件	代码位置	输入	输出
驾驶舱	apps/web/src/views/ChatBIDashboard.vue	summary、用户操作、SSE	指标、图表、洞察、答案
分析工作台	views/WorkspaceView.vue、stores/runStore.ts	Session、Run 事件	时间线、DAG、证据、产物
数据资产	views/DatasourcesView.vue	上传/连接、Schema	Schema 卡片、遮蔽、图谱
模型设置	views/ModelSettingsView.vue	配置、Key	测试结果、激活状态
主 API	apps/api/server	HTTP、环境配置	JSON envelope、SSE
Run 创建	application/run_execution.py	Session、问题、幂等键	Run 记录、排队事件
Run 执行	runtime/run_executor.py、run_runtime.py	RunContext	事件、审计、Artifact、终态
Agent	packages/agent_runtime/graph.py	计划、观察、上下文	工具调用、Claim、答案
SQL 网关	packages/data_gateway/sql_guard.py	SQL、Schema	只读 SQL 或拒绝码
Sandbox	application/docker_sandbox.py	脚本、输入	产物、stdout、错误
DataLink	services/datalink/server	Schema、修订	图谱、语义检索、版本
Metadata	packages/metadata	领域对象	SQLite 记录

3.5 数据持久化

分组	表	用途
数据资产	data_sources、connection_grants、secrets	数据源、授权、加密凭据
模型	model_profiles	服务商、模型、参数、能力快照
会话	sessions、session_preferences、conversation_context_states、historical_answer_summaries	会话、偏好、上下文、历史摘要
消息与 Run	messages、runs	问题、答案、Run 上下文与终态
事件与工具	run_events、tool_calls	事件账本、工具调用摘要
审计与产物	sql_audit_logs、artifacts、artifact_cleanup_tasks	SQL 审计、产物、清理
DataLink	datalink_validations、run_datalink_consumptions	构建校验、语义消费

迁移使用 Alembic，共 31 个版本，覆盖基础元数据、数据源网关、模型运行时、Run 事件、上下文、DataLink 校验与消费。

3.6 部署拓扑

服务	端口	运行方式	对外暴露
Web	5280	Vite / 静态构建	是
FastAPI	8280	Python 3.12、Uvicorn、单 worker	是（仅 API）
DataLink	8281	Python 3.12、Uvicorn	否（内网/本机）
DeepSeek	HTTPS	外部 Responses API	出站

Windows 通过批处理启动三项服务；生产环境使用 HTTPS 反向代理，DataLink 仅内网，storage 与 Metadata 最小权限并定期备份。

3.7 可靠性与安全

- `/health` 检查 Metadata、数据源根、Artifact 根与 DataLink；DataLink 不可用返回 `degraded` 而非 500。
- SSE 中断时停止读取并释放 reader；历史事件可重新拉取。
- 服务启动恢复非终态 Run、数据源检查、DataLink 构建与校验。
- Run 创建使用幂等键；同一 Session 只允许一个活跃 Run。
- 取消写入登记，执行器在检查点终止并落 `run.canceled`；总超时默认 600 秒。
- Key 只在服务端环境变量或加密 Secret；DataLink 不面向公网；日志不记录 Authorization、Key、完整查询结果。

4 AI 技术方案

4.1 选型结论

主分析模型选择 **DeepSeek deepseek-flash**，通过 OpenAI Python SDK 的 **Responses API** 接入，`base_url=https://api.deepseek.com`，`stream=true`。

维度	要求	匹配度
中文理解	理解“回款”“毛利率”“同期”“区域占比”	中文语料充分，业务词稳定
工具调用	按 JSON Schema 调用 4 个白名单工具	支持 tool calling
流式输出	首片延迟低，逐片渲染	支持 output_text.delta
接口兼容	复用 OpenAI SDK，便于替换	OpenAI-compatible
成本	演示与回归可承受	flash 档位单价低
推理能力	多步计划、SQL 修复、结论归纳	支持推理模式

备选方案：GPT-4o 系列生态成熟但成本与网络可达性对评审不友好；Qwen 中文强但需额外适配；本地 Ollama 隐私最好但本机算力与上下文不足；纯规则可控但无法处理开放问法。模型通过 ModelProfile 可替换，选型不是硬编码。

4.2 集成方式

```
Browser ──POST /ai/deepseek/analyze──▶ FastAPI
                                       ├─ 读取 DEEPSEEK_API_KEY (环境变量)
                                       ├─ AsyncOpenAI(base_url, api_key)
                                       └─ Responses API(stream=true)
Browser ◀──SSE: status / delta / error / done── FastAPI
```

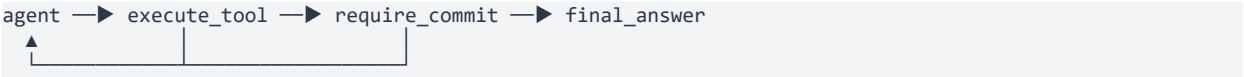
- 浏览器请求体只有 `question`，不接受 Key、Base URL、模型名等敏感参数。
- Key 不进入前端 bundle、localStorage、日志、报告、截图。
- 模型请求由主 API 发起，浏览器不直连模型服务。

上游事件	下游 SSE	前端行为
请求开始	status	进入 analyzing，禁用发送
response.output_text.delta	delta	追加片段，只追加一次
response.completed	done	清除 loading，显示来源与限制
failed / 异常	error	稳定错误消息，必要时降级
incomplete / 截断	截断标记	提示答案不完整

错误分类：401 `invalid_api_key` 不重试；402 `insufficient_balance` 不重试；timeout / connection 未输出时有限退避；429 / 5xx 指数退避最多 2 次；已输出后中断不重放。

4.3 受控 Agent Runtime

Agent 基于 LangGraph 构建，节点为：



外层阶段：`Opening → Preparation → Protocol → Discovery → Analysis → Commit → Final Answer`。

阶段	职责	关键约束
Opening	判断是否需要数据、是否澄清	60 秒
Preparation	冻结 Schema、模型、DataLink 版本	240 秒共享窗口
Protocol	general-task / ready / discovery / context_only / clarification	结构化选择
Discovery	探索表、字段、行数、关系	最多 2 次尝试
Analysis	多轮工具调用与观察	≤20 回合
Commit	提交 Claim / Assertion	≤2 次校验失败
Final Answer	Markdown + 引用 + 证据快照	45 秒

4.4 工具白名单

工具	作用	关键约束
run_sql_readonly	只读查询	AST 校验、字段白名单、LIMIT、超时、审计
run_python	计算与产物	Docker 隔离、禁网、限资源、固定入口
explore_datalink	语义检索	MCP、版本化、消费记录、授权范围
commit_analysis_claims	提交结构化结论	Claim/Assertion 合同、事实校验、引用绑定

除这四个工具外，模型不能调用文件系统、网络、Shell 或任意代码执行。

4.5 预算与熔断

配置	默认值	作用
AGENT_MAX_TURNS	20	单 Run 最大回合
AGENT_MAX_DATA_TOOL_CALLS	16	数据工具总调用
AGENT_MAX_STAGE_TOOL_FAILURES	2	同阶段连续失败后收尾
AGENT_MAX_COMMIT_VALIDATION_FAILURES	2	Claim 校验重试
AGENT_MAX_SANDBOX_REJECTIONS	2	沙箱安全拒绝
AGENT_MAX_SQL_REPAIRS	2	SQL 改写次数
AGENT_MAX_DISCOVERY_ATTEMPTS	2	Discovery 初次 + 修复
AGENT_MAX_MODEL_MESSAGES	32	工作集消息上限
AGENT_MAX_MODEL_CONTEXT_CHARS	64000	工作集字符预算
AGENT_MAX_TOOL_MESSAGE_CHARS	32000	单条观察截断

配置	默认值	作用
AGENT_MAX_TOTAL_ASSERTIONS	8	单 Run 检查项
AGENT_MAX_QUERY_ATTEMPTS_PER_ASSERTION	3	单检查项查询

熔断的意义：把“模型无限重试”变成“有界失败”。当工具连续失败、SQL 反复被拒、Claim 反复校验不过时，Run 进入部分完成或失败终态，并给出可读原因。

4.6 可信分析机制

```
用户目标
  → AnalysisRequirement（需求项）
  → AnalysisPlan（目标、完成条件、最小字段）
  → AnalysisAssertion（结构化检查项）
  → 工具查询（SQL / Python / DataLink）
  → AnalysisClaim（结构化事实）
  → Validation（事实 / 结果 / 引用 / 产物）
  → AnswerMaterial（可引用材料）
  → Evidence Snapshot（答案落库时冻结证据）
```

规则	说明
数字必须来自查询	上下文外数字不得作为事实
口径必须可解释	毛利率 = 毛利 / 订单金额；待回款只统计对应状态
同期必须对齐	10 月 1–29 日对比 9 月 1–29 日
缺字段必须拒答	无漏斗字段不算转化率；无成本字段不算毛利率
引用必须存在	[n] 必须对应材料编号；未引用材料不进入结论
产物必须可定位	Artifact 有 ID、类型、路径与来源 Run
部分完成必须标注	未满足全部断言时输出缺口

4.7 数据访问安全

SQL 只读网关流程：

```
原始 SQL
  ├─ SQLGlot 解析 AST
  ├─ 必须是 Query；拒绝 INTO / INSERT / UPDATE / DELETE / CREATE / DROP
  ├─ 表白名单 + 字段白名单（Schema 与遮蔽）
  ├─ LIMIT：缺省 100；显式整数且 ≤ 500
  ├─ 单次超时 60s
  └─ 写入 sql_audit_logs（原始/规范化 SQL、状态、拒绝码、行数、耗时）
```

Python 沙箱：`--network none`、`--cpus 1`、`--memory 512m`、`--pids-limit 64`、`--cap-drop ALL`、只读根文件系统；固定入口 `python analysis.py`；30 秒超时；产物写入受控目录并登记 Artifact。

字段遮蔽：数据源接入生成敏感字段建议清单；用户必须显式确认 `mask_fields` 与 `mask_fields_confirmed`；未确认时创建 Run 返回 409；遮蔽字段不进入 Schema 投影、SQL 白名单、模型上下文与报告。

4.8 DataLink 语义图谱

1. 读取 Schema：表、字段、类型、主键、外键、行数、样例。

2. 模型生成实体、属性、关系与 Join 线索草稿。

3. 人工修订：合并同义实体、修正字段映射、确认关系。

4. 校验：结构、引用完整性、字段存在性。

5. 发布版本：每次发布形成不可变 revision，Run 创建时冻结版本。

6. 检索与消费：MCP 按业务词召回；每次调用写入 `run_datalink_consumptions`。

价值：降低模型猜字段、猜表名、猜 Join 的概率；把业务术语与物理模型解耦；版本化保证历史 Run 可复现。

4.9 优化策略

策略	做法	效果
最小 Schema 投影	只发送当前任务相关表/字段	降低 token 与误选
工作集裁剪	保留最近消息、计划、关键观察与结论	消息数 ≤32
单条观察截断	超过 32000 字符截断并标注	防止单条结果撑爆上下文
压缩循环	超预算时按步骤压缩历史	保留事实，丢弃冗余
语义上下文限时	DataLink 阶段 30 秒	避免建图慢拖垮 Run
输出预算分离	输出 16384，输入按窗口减输出与 6144 预留	防止答案被截断
SQL 先探索后分析	Discovery 限制 2 次	减少盲目查询
SQL 修复有界	最多 2 次改写	防止无限试错
默认 LIMIT 100	结果足够分析，避免全表	降低延迟与传输
沙箱按需	只有需要计算/图表产物时才调用	降低 Docker 依赖
流式优先	首片即渲染，空闲 30 秒超时	体感更快，异常可感知
事件驱动 UI	SSE 增量投影，不轮询	降低请求与延迟

成本优化：使用 flash 档位；只发送聚合摘要；工具调用、回合、输出 token、总时长均有上限；DataLink 语义结果按版本缓存；LangSmith 仅在需要时开启。

4.10 评测体系

层级	规模	内容
后端 Pytest	772 项通过	Agent、SQL 网关、Run、DataLink、模型、工具、安全、迁移
前端 Vitest	40 个文件 / 282 项通过	组件、stores、事件投影、引用、布局、主题
类型与构建	通过	vue-tsc、Vite build
规范	通过	Ruff（E/F/I/UP/B）
真实依赖	默认排除	live_model、live_docker 需真实 Key / 镜像

中文电商基准：20 题，覆盖计数、分组、金额、时间、排名、对比、占比；`expected-answers.json` 是唯一 gold；评分采用 0.05% 相对容差 + 小数位舍入 + 字符串/月份同义匹配 + 单元格匹配；`score_benchmark.py --lint` 检查题号、gold、行数、列数与同源关系。

协议路由评测：178 条语料、11 类场景（问候、概念、当前数据、Schema、Discovery、混合、隐式、数据词概念、澄清、约束、对抗），评估模式准确率、终态类型、资源类型与失败分布。

Prompt A/B：`prompt_ab_experiment.py` 绕过 Runtime 直接调用模型，隔离提示解释与超时、Pydantic、SQL 校验的影响，记录变体、耗时、token 与结构化结果。

评测结果用于回归与选型参考，不对外宣称“全面领先”；真实企业数据需另行验收。

4.11 准确性与隐私

- 事实来自查询：模型只归纳已查询到的数据。
- 断言校验：Claim 必须匹配查询结果；不匹配则重试或部分完成。
- 引用绑定：答案数字附材料编号；无引用的事实不进入结论。
- 缺口显式：字段缺失、查询失败、行数截断都在答案中说明。
- 只发送最小必要聚合，不发送客户姓名、订单行、完整 CSV。
- 遮蔽字段不进入 Schema、SQL、上下文与报告。
- 日志不记录 Authorization、Key、完整结果、模型完整上下文。

4.12 失败模式与降级

失败	系统行为	用户可见
无 Key	演示模式 / 本地确定性回答	“演示模式”标签
401 / 402	不重试，记录类别	检查 Key / 余额
超时 / 429 / 5xx	未输出时有限退避	“正在重试”或“暂时不可用”
输出中断	不重放	“回答中断，请重试”
SQL 被拒	返回拒绝码，Agent 可修复	审计可见，答案说明限制

失败	系统行为	用户可见
沙箱拒绝	计入拒绝预算，收尾	脚本未通过安全策略
DataLink 不可用	降级为 Schema 浏览	语义增强不可用
证据不足	部分完成	缺失项与建议
需要澄清	终止并提问	澄清问题，不强行猜测

5 核心功能实现

5.1 经营驾驶舱



智析 ChatBI 经营驾驶舱

驾驶舱是评审第一眼看到的主界面，信息层级为“状态 → 指标 → 趋势 → 问数 → 洞察 → 明细”：

- 顶部：面包屑、实时状态、日期、刷新、提醒、导入数据。
- 指标卡：10 月截至 29 日订单金额 85.4 万元、活跃客户 73、平均订单金额、累计毛利率 40.1%。
- 营收趋势：2026 年 1–10 月月度营收与毛利双折线，标注“10 月 1–29 日较 9 月同期 +1.05%”。
- AI 智能洞察：区域占比、待回款、毛利率变化等信号，每条可展开。
- 问数区：中文输入、推荐问题、数据源标签、“只读分析 · 数据安全”。
- 答案卡：问题、结论、来源、证据入口。
- 底部：收入来源环图、区域 TOP5、经营预警（73 笔待回款、毛利率 41.5%）。

所有数字来自 `chatbi_sales_summary.json`，页面不维护第二套业务数值。ECharts 在挂载时初始化、卸载时 dispose，ResizeObserver 负责尺寸变化。

5.2 智能问数

问数有三条路径：

路径	条件	行为
真实 Run	数据源 ready + 遮蔽确认 + 模型激活	创建 Session/Run，订阅事件，展示答案与证据
DeepSeek 演示	有 Key、无真实数据源	服务端聚合上下文，SSE 流式回答
本地降级	无 Key / API 不可用	确定性回答，保留来源标签与报告导出

输入规则：1–2000 字符；Enter 发送，Shift+Enter 换行；空值、纯空白、超长阻止；分析期间禁用发送；推荐问题填充并聚焦；新问题不覆盖未完成的上一条回答。

5.3 受控分析工作台

工作台采用“左会话 / 中答案 / 右检查台”三栏：

- 左：Session 列表、当前数据源、Run 历史。
- 中：答案正文、`[n]` 引用、材料查看、Artifact 预览与下载。
- 右：运行检查台，包含阶段、工具调用、SQL 审计、DataLink 消费、证据与 Trace DAG。

Run 事件账本包含 25 类事件，SSE 与历史回放共用同一份事实。前端 `runStore` 将事件投影为状态、阶段、工具、审计、产物与 DAG；`RunTraceDag` 负责节点排序、折叠与布局；`AnswerMaterialViewer` 展示材料来源、查询审计与结果表格。

5.4 DataLink 工作台

数据资产页承载 DataLink 的完整生命周期：

1. Schema 浏览：表、字段、类型、行数、主键、关系。

2. 语义建图：实体、属性、关系、字段映射、Join 线索。

3. 人工修订：合并实体、修正映射、确认关系。

4. 校验：结构、引用完整性、字段存在性。

5. 版本：发布不可变 revision，查看历史与差异。

6. 消费：Run 使用记录，保留版本与命中项。

5.5 数据源与模型配置

数据源支持 CSV、SQLite 上传与 MySQL 连接；上传限制扩展名、大小（默认 100MB）与受控目录；Schema 异步检查，失败可重试，服务重启恢复中断检查。

模型设置支持 OpenAI-compatible 服务商、模型名、Base URL、温度、超时、上下文窗口、推理模式；Key 只在提交时传入服务端并加密保存，详情只返回 `has_api_key`；模型必须通过能力测试后才能激活。

5.6 洞察报告、台账与收支

报告包含问题、结论、数据来源、更新时间、证据状态与限制说明，可导出 Markdown；演示与真实来源明确区分，真实报告附引用编号。

项目台账展示项目名称、负责人、阶段、进度、预计交付与 AI 进度洞察；收支管理展示净现金流、收入、成本、回款状态与明细。V1.0 均为演示记录，不写入外部系统。

5.7 前端工程与视觉

维度	实现
框架	Vue 3 + TypeScript + Vite + Pinia + ECharts + Tailwind CSS 4
路由	/workspace、/analysis、/datasources、/settings/model
状态	session / datasource / model / run / artifact 五个 store
事件	SSE 增量投影，历史事件回放，失败重连
视觉	深海黑背景 #050607、朱砂橙主色 #d94b32、蓝紫焦点 #8292ff、成功绿 #76b7a0
质感	玻璃面板、径向光晕、鼠标位置驱动微位移、prefers-reduced-motion 降级
响应式	850px 侧栏收窄，680px 单列，390px 无页面级横向溢出
无障碍	语义按钮、焦点可见、图表 aria-label、颜色 + 图标 + 文字三重表达

6 测试与部署

6.1 测试策略

层级	范围	工具
单元	工具函数、契约、校验、投影、格式化	Pytest / Vitest
集成	Run 创建、事件、SQL 网关、DataLink、模型配置	Pytest
接口	HTTP envelope、SSE、错误分类、健康检查	Pytest / httpx
AI 评测	20 题基准、178 条路由、Prompt A/B	自研脚本
手工	响应式、无障碍、降级、启动脚本、文档渲染	Edge / 批处理
真实依赖	真实模型、Docker 沙箱	live_model / live_docker 标记

6.2 测试结果

测试项	结果
后端 Pytest	772 项通过
前端 Vitest	40 个文件、282 项通过
DeepSeek 单测	6 项通过
Ruff	全量通过
vue-tsc	通过
Vite 生产构建	通过
FastAPI 健康检查	healthy
DataLink 健康检查	graph_database=ok，MCP mounted
Web 页面	HTTP 200
DeepSeek SSE	HTTP 200，收到 delta 与 done
Windows 一键启动	DataLink / API / Web 全部启动
Word / PDF 渲染	18 份 DOCX 已生成；关键文档转 PDF 复核

6.3 演示数据核对

指标	实际值
订单数	906
客户数	179
累计订单金额	8,079,554.17 元
累计毛利	3,236,767.66 元
累计毛利率	40.06%

指标	实际值
待回款订单	73 笔
10 月截至 29 日订单金额	853,824.14 元
与 9 月同期变化	+1.05%
当期毛利率	41.50%
当期回款率	93.13%

6.4 构建与启动

```
py -3.12 -m venv .venv
.venv\Scripts\python.exe -m pip install uv
.venv\Scripts\uv.exe sync --locked --group dev
powershell -ExecutionPolicy Bypass -File scripts\install-frontend.ps1
.venv\Scripts\python.exe -m tools.prepare_local
.venv\Scripts\python.exe -m alembic upgrade head
powershell -ExecutionPolicy Bypass -File scripts\dev-services.ps1 -Action Start
```

也可直接运行根目录“安装并启动智析 ChatBI.bat”；后续使用“启动智析 ChatBI.bat”，停止与状态分别使用“停止智析 ChatBI.bat”“查看智析 ChatBI 状态.bat”。

6.5 部署与安全

- Web、API 使用 HTTPS 反向代理；FastAPI 单 worker；DataLink 仅内网。
- Key 通过环境变量或部署 Secret 注入；不得写入批处理、前端变量、issue 或截图。
- storage 最小权限；备份 Metadata 与 Artifact；保留 Alembic revision、代码 tag 与锁文件。
- 反向代理关闭 SSE 缓冲并设置合理 read timeout。
- 监控 API/DataLink 健康、401/402/429、Run failed、SSE 中断、磁盘与模型费用。

6.6 已知限制

编号	限制	处理
L-01	真实企业数据需现场接入并确认遮蔽	数据源接口已具备，部署前配置
L-02	Python 产物需 Docker Sandbox	SQL/DeepSeek 演示不依赖 Docker
L-03	DeepSeek 需要有效 Key 与余额	缺失时进入演示降级
L-04	项目台账与财务明细为演示记录	不向外部业务系统写入
L-05	单工作空间，无多租户/SSO	明确 V1.0 边界，列入演进

7 创新点

7.1 技术创新点

创新点 1：受控 Agent Runtime，而不是自由 ReAct。

平台用 LangGraph 状态机固定“Opening → Preparation → Protocol → Discovery → Analysis → Commit → Final Answer”的阶段，模型只能在阶段内选择 4 个白名单工具，并受回合、工具、失败、SQL 修复、沙箱拒绝、断言失败等多重预算约束。自由 Agent 的常见问题是无限试错、越权调用与不可复现；受控运行时把这些问题变成有界失败和可读终态。

创新点 2：Claim / Assertion / Evidence 的证据链闭环。

模型在最终答案前必须提交结构化 Claim；运行时把需求拆成 Assertion，与查询结果比对；答案中的每个数字绑定材料编号；答案落库时保存 Evidence Snapshot。结论不是“模型说的”，而是“查询事实 + 校验 + 引用”的组合，可回放、可审计。

创新点 3：SQL 只读网关 + Docker 无网络沙箱的组合边界。

SQL 经 SQLGlot AST 校验，拒绝写语句、越权表/字段，强制 LIMIT 与超时，并记录每次尝试；需要复杂计算时进入 `--network none`、`--cap-drop ALL`、只读根文件系统、512MB/1CPU/64 PID 的沙箱。模型没有任何直接写库或联网执行代码的能力。

创新点 4：DataLink 语义图谱 + MCP 版本化检索。

把业务实体、属性、物理字段、关系与 Join 线索做成独立语义服务，通过 MCP 提供给 Agent；每次发布形成不可变 revision，Run 创建时冻结版本，消费记录可追溯。它解决“业务词不是字段名”的最后一公里，也让换库、重构与历史复现成为可能。

创新点 5：同一事件账本同时服务 SSE 与历史回放。

25 类 Run 事件既是实时推送的事实，也是历史回放的事实；前端用同一套投影逻辑处理实时与回放。避免了“实时状态”和“历史记录”双写不一致，也让 Trace DAG、证据与产物可以按事件重建。

创新点 6：演示 / 真实双模式与可复现评测。

无 Key、无企业数据时仍可完整演示；真实模式需要 ready 数据源、遮蔽确认、模型激活。配套 20 题中文电商基准、178 条协议路由用例与 Prompt A/B 脚本，使 AI 质量可回归，而不是“演示一次就结束”。

7.2 应用创新点

应用创新点 1：对话即分析，而不是聊天窗 + 图表。

自然语言输入位于驾驶舱中部偏下，是页面的交互中心；提问后答案、图表、来源与证据在同一工作台呈现，用户不需要在聊天工具、SQL 客户端和 BI 工具之间切换。

应用创新点 2：让非技术管理者“看得懂、敢相信”。

指标卡先给结论，再给口径与截至日期；答案标注来源、时间范围与限制；证据入口可展开 SQL 审计与材料。它把“AI 说的”变成“有依据的分析”。

应用创新点 3：经营驾驶舱 + 问数 + 报告 + 台账 + 收支的一体化。

不只是问数 Demo，而是把企业经营常用的驾驶舱、洞察报告、项目台账与收支管理放进同一产品，形成可演示、可扩展的业务闭环。

应用创新点 4：低门槛评审与真实落地共用一套产品。

评审无需 Key 即可完成主流程；企业接入时只需准备数据源、确认遮蔽、激活模型。演示与真实不是两套代码，而是同一运行时的两种模式。

应用创新点 5：把安全边界做成产品能力。

字段遮蔽确认、只读 SQL、沙箱隔离、密钥托管、日志脱敏不是文档里的承诺，而是页面状态、接口冲突（409）、审计记录与运行预算的一部分。

7.3 与常见方案的差异

维度	聊天工具 + CSV	传统 BI	智析 ChatBI
使用门槛	低	高	低
数据接入	手工上传	建模后接入	CSV / SQLite / MySQL
结论来源	常无来源	报表口径	SQL 审计 + Artifact + 引用
写库风险	取决于工具	受权限控制	只读网关 + 沙箱
语义映射	无	人工建模	DataLink 图谱 + MCP
可回放	弱	报表历史	Run 事件账本
评审可复现	需 Key	需环境	演示模式无需 Key

8 总结与展望

8.1 已完成

- 完成驾驶舱、问数、分析工作台、数据资产、模型设置、报告、台账与收支的完整产品闭环。
- 完成受控 Agent Runtime、SQL 只读网关、Python 沙箱、DataLink 语义图谱与证据链。
- 完成 Windows 一键启动、Alembic 迁移、双模式运行与演示数据。
- 完成后端 772 项、前端 282 项测试，Ruff、vue-tsc、生产构建通过。
- 完成 20 题中文电商基准、178 条协议路由语料与 Prompt A/B 脚本。
- 完成 18 份开发文档、技术文档与作品介绍材料。

8.2 局限

- 真实企业数据、组织权限与生产规模性能尚未在目标环境验收。
- Python 产物依赖 Docker；无 Docker 时只能使用 SQL 与演示路径。
- DataLink 建图质量依赖模型与人工修订，尚未覆盖所有行业术语。
- 单工作空间，不含多租户、SSO 与行级权限。
- 模型能力与成本随供应商变化，需要持续评测与路由。

8.3 展望

1. **指标层**：把毛利率、回款率等口径固化为可复用指标，减少重复解释。
2. **更强检索**：DataLink 引入向量召回与术语表，提升业务词命中。
3. **多模型路由**：按任务复杂度在 flash 与更强模型间路由，兼顾成本与质量。
4. **评测扩展**：从 20 题扩到多行业题库，加入人工评分与事实覆盖率。
5. **权限与多租户**：组织、角色、行级权限与脱敏策略。
6. **离线私有化**：支持本地模型与私有 DataLink，满足数据不出域。
7. **移动端与订阅**：经营简报推送、移动驾驶舱与异常提醒。

8.4 结语

智析 ChatBI 想证明的不是“大模型会聊天”，而是“大模型可以在企业数据场景里被安全地使用”。当模型被放进受控运行时、当每个数字都有证据、当没有 Key 也能完整演示，AI + BI 才从概念走向可用。这套架构可以继续扩展行业语义、指标层与权限体系，也可以作为其他企业数据 Agent 的参考实现。

附录 A 关键代码与文档索引

关注点	入口
前端路由	apps/web/src/router.ts
驾驶舱	apps/web/src/views/ChatBIDashboard.vue
分析工作台	apps/web/src/views/WorkspaceView.vue、stores/runStore.ts
数据资产	apps/web/src/views/DatasourcesView.vue
模型设置	apps/web/src/views/ModelSettingsView.vue
主 API	apps/api/server/app.py、routes/*.py
Run 创建	apps/api/application/run_execution.py
Run 执行	apps/api/runtime/run_executor.py、run_runtime.py
Agent 状态机	packages/agent_runtime/graph.py
SQL 网关	packages/data_gateway/sql_guard.py
Python 沙箱	apps/api/application/docker_sandbox.py
元数据	packages/metadata/models.py、migrations/versions/
DataLink	services/datalink/server/
演示数据	data/demo/chatbi_sales.csv、chatbi_sales_summary.json
评测题库	data/benchmark/ecommerce-cn/
文档基线	docs/01–docs/18

附录 B 环境变量分组

分组	代表变量	说明
基础运行	APP_ENV、API_HOST、API_PORT、API_WORKERS	默认 8280，单 worker
受控存储	DATASOURCE_ROOT、ARTIFACT_ROOT、SCRIPT_WORKSPACE_ROOT	全部位于 storage/
DataLink	DATALINK_BASE_URL、DATALINK_MCP_URL、DATALINK_LLM_*	默认 8281，MCP 为 /mcp
数据访问	DEFAULT_QUERY_LIMIT、MAX_QUERY_LIMIT、QUERY_TIMEOUT_SECONDS	默认 100 / 500 / 60 秒
Run 预算	AGENT_MAX_TURNS、AGENT_MAX_DATA_TOOL_CALLS、AGENT_MAX_TOTAL_ASSERTIONS	回合 / 工具 / 断言

分组	代表变量	说明
模型	DEEPSEEK_API_KEY、DEEPSEEK_BASE_URL、DEEPSEEK_MODEL	Key 仅服务端
可观测	LANGSMITH_TRACING、LANGSMITH_API_KEY、LANGSMITH_PROJECT	默认关闭
Web	CORS_ORIGINS、VITE_API_BASE_URL	默认 http://localhost:5280

完整模板见仓库根目录 `.env.example`；所有值均为空或安全默认，真实密钥不得提交。

附录 C 术语表

术语	含义
Session	一次连续对话会话
Run	一个问题对应的一次独立分析运行
RunContext	Run 创建时冻结的数据源、Schema、模型、DataLink 与预算
Opening	判断问题类型、是否需要数据与澄清
Discovery	探索表、字段、行数与关系
Claim	模型提交的结构化事实
Assertion	把需求拆成的可验证检查项
Evidence Snapshot	答案落库时冻结的证据状态
Artifact	查询结果、图表或文件等受控产物
DataLink	业务实体、属性、字段与关系组成的语义地图
MCP	Model Context Protocol，DataLink 对外提供的语义检索协议
Trace DAG	由 Run 事件推导的执行关系图